# Comparación de métodos de segmentación (umbralización RGB, Otsu y Gaussian Naive Bayes) en imágenes de esquejes de camote y su efecto en el área y el perímetro estimados

*Comparison of segmentation methods (RGB thresholding, Otsu, and Gaussian Naive Bayes) in sweetpotato cutting images and their effect on estimated area and perimeter*

Nixon Forero Giraldo (nforerog1@eafit.edu.co), Mariana Foronda Cadavid (mforondac@eafit.edu.co) y Juan Esteban Arciniegas Espitia (jearciniem@eafit.edu.co)

Pregrado: Ingeniería Agronómica, Universidad EAFIT, Medellín, Colombia.
Curso Big Data y Bioinformática

## Resumen

La segmentación de imágenes RGB es el paso previo a la medición de rasgos morfológicos de las plantas, pero rara vez se verifica si las mediciones dependen del método elegido. Este estudio compara tres métodos —umbralización de la banda azul (RGB, B < 85), método de Otsu y clasificación de píxeles con Gaussian Naive Bayes (Bayes)— en 60 imágenes de esquejes de camote sobre fondo claro del conjunto PlantSegDatasets, y evalúa su efecto sobre el área y el perímetro medidos con PlantCV. El clasificador Bayes alcanzó una exactitud de .89 en 100 píxeles de prueba. El área no fue normal (Shapiro-Wilk, $p \leq .006$) y el perímetro sí ($p \geq .111$), por lo que se usaron pruebas no paramétricas pareadas. La prueba de Friedman indicó diferencias entre métodos en ambas variables ($p < .001$) y todos los pares difirieron tras la corrección de Bonferroni. Las medias del área variaron entre 126 654 y 130 614 px (3.1 %) y las del perímetro entre 7 539 y 8 298 px (9.6 %). La diferencia relativa por imagen fue mayor en el perímetro que en el área en RGB–Bayes y Otsu–Bayes ($p < .001$), pero no en RGB–Otsu ($p = .560$). Sin máscaras de referencia, se mide discrepancia entre métodos y no exactitud.

**Palabras clave:** segmentación de imágenes, umbralización, método de Otsu, Naive Bayes gaussiano, fenotipado de plantas, PlantCV, pruebas no paramétricas.

## Abstract

Segmenting RGB images precedes the measurement of plant morphological traits, yet whether those measurements depend on the segmentation method is seldom checked. We compared three methods—thresholding of the blue band (RGB, B < 85), Otsu's method, and pixel-wise Gaussian Naive Bayes (Bayes)—on 60 sweetpotato cutting images over a light background from the PlantSegDatasets collection, and assessed their effect on area and perimeter measured with PlantCV. The Bayes classifier reached an accuracy of .89 on 100 held-out pixels. Area was non-normal (Shapiro-Wilk, $p \leq .006$) and perimeter was normal ($p \geq .111$), so paired nonparametric tests were used. Friedman's test showed differences among methods for both variables ($p < .001$), and every pair differed after Bonferroni correction. Mean area ranged from 126,654 to 130,614 px (3.1%) and mean perimeter from 7,539 to 8,298 px (9.6%). The per-image relative difference was larger for perimeter than for area in RGB–Bayes and Otsu–Bayes ($p < .001$) but not in RGB–Otsu ($p = .560$). Without reference masks, the study measures between-method discrepancy, not accuracy.

**Keywords:** image segmentation, thresholding, Otsu's method, Gaussian Naive Bayes, plant phenotyping, PlantCV, nonparametric test.

## Introducción

El fenotipado de plantas basado en imágenes permite medir rasgos de forma no destructiva y repetible, y plataformas de código abierto como PlantCV han estandarizado la extracción de rasgos como el área proyectada y el perímetro (Gehan et al., 2017). Todas parten de una máscara binaria que separa la planta del fondo, de modo que la segmentación condiciona cada medición posterior. Los índices de color desarrollados para aplicaciones concretas pueden no adaptarse de forma robusta a condiciones de captura variables (Lu et al., 2022b).

Entre las alternativas figuran la umbralización con un valor fijo elegido por el analista, los umbrales automáticos como el método de Otsu (1979) y los clasificadores de píxeles como Gaussian Naive Bayes, que modela cada canal de color como una distribución normal por clase y supone independencia condicional entre canales. Esa suposición rara vez se cumple, pero el clasificador suele clasificar bien (Domingos y Pazzani, 1997).

Cada método produce una máscara ligeramente distinta, y la pregunta práctica es si esas diferencias alteran las variables de interés. El área depende sobre todo del interior de la planta, mientras que el perímetro acumula la longitud de cada irregularidad del contorno, por lo que se espera que sea más sensible. Los objetivos fueron: (a) comparar tres métodos de segmentación bajo un mismo pre y posprocesamiento; (b) contrastar con pruebas no paramétricas si el área y el perímetro difieren entre métodos; y (c) evaluar si la diferencia relativa entre métodos es mayor en el perímetro que en el área.

## Método

### Descripción del dataset

Se utilizó PlantSegDatasets, publicado en Kaggle por el usuario yuzhenlu (Lu, 2022a; https://www.kaggle.com/datasets/yuzhenlu/plantsegdatasets). Según su página, contiene dos conjuntos de imágenes a color (.jpg): malezas adquiridas en condiciones naturales de campo (50 imágenes) y esquejes o guías de camote (*sweetpotato slips/vine cuttings*) adquiridos en interiores (60 imágenes). Los datos se prepararon originalmente para evaluar métodos de segmentación de plantas (Lu et al., 2022b), artículo que quien publica el dataset solicita citar.

Este estudio usa únicamente el conjunto de esquejes de camote, es decir, las 60 imágenes (archivos DSC00134 a DSC00252, no consecutivos). No se empleó el conjunto de malezas porque sus condiciones de campo implican fondos complejos e iluminación variable; en cambio, las imágenes de interior muestran varios esquejes sobre una superficie gris clara y homogénea (Figura 1), lo que permite atribuir las diferencias al método y no al fondo. Es adecuado para una comparación controlada, pero limitado a un cultivo, un entorno y 60 imágenes. Las imágenes originales tienen una resolución de 1224 × 918 px, y el dataset se publicó en 2022 bajo la licencia Attribution-NonCommercial 4.0 International (CC BY-NC 4.0; https://creativecommons.org/licenses/by-nc/4.0/).

**Figura 1**

*Ejemplos de imágenes del conjunto de esquejes de camote*



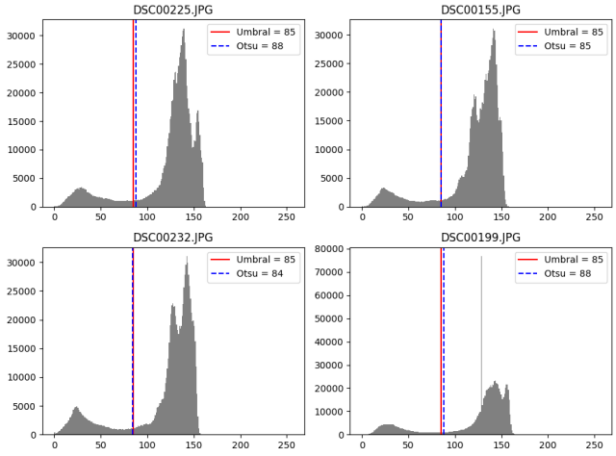
*Nota.* Cuatro de las 60 imágenes analizadas, antes del recorte (Lu, 2022a).

### Preprocesamiento y segmentación

Todas las imágenes se recortaron con la misma ventana (filas 20–850 y columnas 20–1180), con lo que se obtuvo una región de 830 × 1160 px. En la banda azul la planta es más oscura que el fondo y el histograma es bimodal, por lo que esta banda alimentó los dos métodos de umbralización. En **RGB** se clasificó como planta todo píxel con B < 85, valor elegido visualmente en el valle de los histogramas de seis imágenes tomadas al azar (semilla 42). En **Otsu** el umbral se calculó para cada imagen con scikit-image (Otsu, 1979) y se aplicó la misma regla; en esas seis imágenes fue de 84 a 88 (Figura 2). En **Bayes** se entrenó un clasificador GaussianNB (Pedregosa et al., 2011) con 500 píxeles etiquetados manualmente (250 Fondo y 250 Planta, descritos por R, G y B), con partición estratificada 80/20 (400 para entrenamiento y 100 para prueba; semilla 42), y se clasificó cada píxel de las 60 imágenes.

**Figura 2**

*Histogramas de la banda azul con el umbral RGB y el umbral de Otsu*




*Nota.* Cuatro de las seis imágenes al azar. Línea roja: RGB (85); línea azul discontinua: Otsu (88, 85, 84 y 88).

A las tres máscaras se les aplicó el mismo posprocesamiento: apertura y cierre con un disco de radio 1, eliminación de objetos menores de 100 px y relleno de huecos menores de 100 px. El área (número de píxeles de la máscara) y el perímetro se midieron con el módulo de tamaño de PlantCV (Gehan et al., 2017) y se expresan en píxeles, pues no se definió una escala física.

### Análisis estadístico

Para cada variable y método se calcularon media, mediana, desviación estándar (DE), mínimo, máximo, coeficiente de variación (CV = DE / media × 100) y valores atípicos (regla de 1.5 veces el rango intercuartílico), junto con la prueba de Shapiro-Wilk. El diseño es pareado: las mismas 60 imágenes se segmentaron con los tres métodos. Dado que el área no es normal y tiene atípicos, y que el perímetro es normal pero presenta un atípico extremo en Bayes, se aplicaron las mismas pruebas no paramétricas a ambas variables, lo que además las hace comparables: (1) prueba de Friedman entre los tres métodos; (2) prueba de Wilcoxon por pares con corrección de Bonferroni ($\alpha = .05 / 3 = .0167$); y (3) prueba de Wilcoxon de sensibilidad, que compara por imagen la diferencia relativa entre dos métodos en el perímetro y en el área, calculada como $|x - y| / ((x + y) / 2) \times 100$. Se declaró al perímetro más sensible si $p < \alpha$ y su mediana fue mayor. Los análisis se ejecutaron en Python (SciPy; Virtanen et al., 2020).

## Resultados

### Estadísticos descriptivos y distribución

La Tabla 1 resume los estadísticos. Las medias del área variaron entre 126 654 px (Bayes) y 130 614 px (Otsu), y las del perímetro entre 7 539 px (Otsu) y 8 298 px (Bayes). El CV fue de 26.2 % a 28.5 % en el área y de 30.2 % a 30.8 % en el perímetro. El área presentó entre 3 y 5 valores atípicos por método, en las plantas más grandes, y el perímetro solo uno: un valor de 16 610 px en Bayes (Figura 5). La Figura 3 muestra máscaras de Bayes tras el posprocesamiento.

El área no siguió una distribución normal en ningún método (Shapiro-Wilk, $p$ = .006, .001 y .005 para RGB, Otsu y Bayes; asimetría de 1.08 a 1.28), mientras que el perímetro sí ($p$ = .122, .205

y .111; asimetría de −0.14 a 0.28). Esto justifica el uso de pruebas no paramétricas para ambas variables.

**Figura 3**

*Ejemplos de segmentación con Bayes*




*Nota.* Imágenes originales y máscaras posprocesadas: esquejes separados (DSC00135) y agrupados (DSC00230).

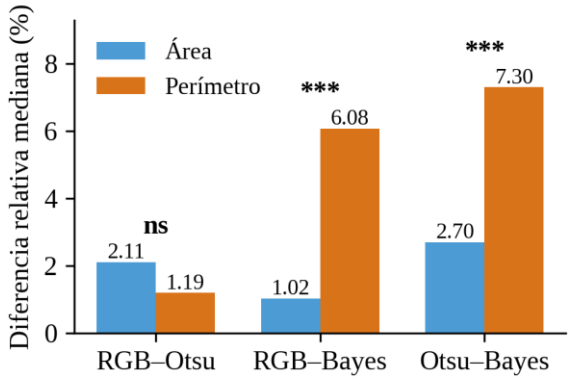
## Pruebas de hipótesis

La prueba de Friedman indicó que los tres métodos difieren en el área ($\chi^2(2) = 32.69$, $p < .001$) y en el perímetro ($\chi^2(2) = 54.86$, $p < .001$; Tabla 2). En las comparaciones por pares con Bonferroni, los tres pares difirieron en ambas variables. La diferencia entre medias fue de 0.68 % a 3.08 % en el área y de 2.26 % a 9.59 % en el perímetro; la menor evidencia fue la del par RGB–Otsu en el perímetro ($p = .012$, apenas por debajo de $\alpha = .0167$). Con 60 pares, incluso una diferencia de 0.68 % en el área (RGB–Bayes) resultó significativa, de modo que la significancia no equivale a relevancia práctica.

En la prueba de sensibilidad, la diferencia relativa mediana por imagen fue mayor en el perímetro que en el área en RGB–Bayes (6.08 % frente a 1.02 %) y en Otsu–Bayes (7.30 % frente a 2.70 %), ambos con $p < .001$. En RGB–Otsu no hubo diferencia significativa (1.19 % en el perímetro y 2.11 % en el área; $p = .560$; Figura 4).

**Figura 4**

*Diferencia relativa mediana entre métodos en el área y el perímetro*




*Nota.* Mediana de la diferencia relativa por imagen (%). ***: p < .001; ns: no significativo (Wilcoxon, α = .0167).

## Desempeño del clasificador Bayes

En los 100 píxeles de prueba, el clasificador alcanzó una exactitud de .89. La precisión fue de .882 para Fondo y de .898 para Planta. La matriz de confusión mostró 45 píxeles de Fondo y 44 de Planta bien clasificados, 5 de Fondo clasificados como Planta y 6 de Planta como Fondo (sensibilidad de .90 y .88, calculada a partir de la matriz). Esta exactitud corresponde a píxeles aislados y no a máscaras completas.

**Tabla 1**

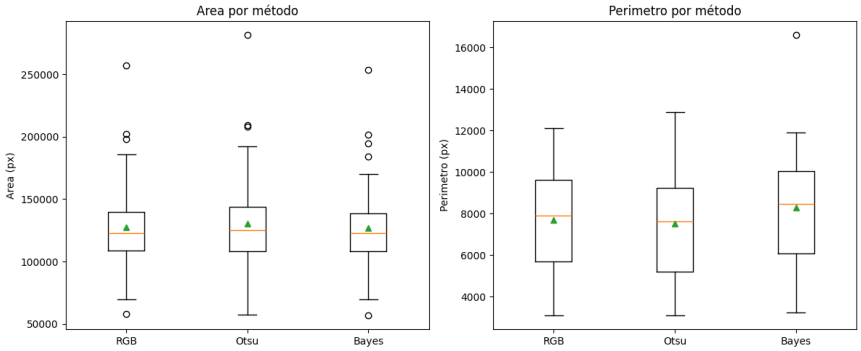
*Estadísticos descriptivos del área y el perímetro según el método (n = 60 imágenes)*

| Variable | Método | Media | Mediana | DE | Mín. | Máx. | CV (%) | Atípicos |
|---|---|---|---|---|---|---|---|---|
| Área (px) | RGB | 127 524 | 122 704 | 33 784 | 57 992 | 256 924 | 26.5 | 4 |
| | Otsu | 130 614 | 125 186 | 37 262 | 57 353 | 281 546 | 28.5 | 3 |
| | Bayes | 126 654 | 122 856 | 33 246 | 56 832 | 253 763 | 26.2 | 5 |
| Perímetro (px) | RGB | 7 711 | 7 907 | 2 373 | 3 104 | 12 139 | 30.8 | 0 |
| | Otsu | 7 539 | 7 644 | 2 321 | 3 109 | 12 878 | 30.8 | 0 |
| | Bayes | 8 298 | 8 461 | 2 503 | 3 260 | 16 610 | 30.2 | 1 |

*Nota.* DE = desviación estándar; CV = coeficiente de variación; atípicos según la regla de 1.5 × rango intercuartílico. Bayes = Gaussian Naive Bayes. Valores redondeados al entero (px).

**Figura 5**

*Distribución del área y del perímetro según el método de segmentación*




*Nota.* Diagramas de caja (n = 60). Línea naranja: mediana; triángulo verde: media; círculos: atípicos.

**Tabla 2**

*Pruebas de Friedman, Wilcoxon por pares (Bonferroni) y Wilcoxon de sensibilidad*

| Prueba | Comparación | Resultado | *p* | ¿Difieren? |
|---|---|---|---|---|
| Friedman | Área | $\chi^2(2) = 32.69$ | < .001 | Sí |
| | Perímetro | $\chi^2(2) = 54.86$ | < .001 | Sí |
| Wilcoxon (Bonferroni) | Área: RGB–Otsu | Dif. de medias = 2.39 % | < .001 | Sí |
| | Área: RGB–Bayes | Dif. de medias = 0.68 % | < .001 | Sí |
| | Área: Otsu–Bayes | Dif. de medias = 3.08 % | < .001 | Sí |
| | Perímetro: RGB–Otsu | Dif. de medias = 2.26 % | .012 | Sí |
| | Perímetro: RGB–Bayes | Dif. de medias = 7.34 % | < .001 | Sí |
| | Perímetro: Otsu–Bayes | Dif. de medias = 9.59 % | < .001 | Sí |
| Sensibilidad | RGB–Otsu | Mediana: perímetro 1.19 %, área 2.11 % | .560 | No |
| | RGB–Bayes | Mediana: perímetro 6.08 %, área 1.02 % | < .001 | Sí |
| | Otsu–Bayes | Mediana: perímetro 7.30 %, área 2.70 % | < .001 | Sí |

*Nota.* Wilcoxon por pares: α = .05 / 3 = .0167. Sensibilidad: mediana de la diferencia relativa por imagen (%) entre dos métodos; «Sí» indica que el perímetro es más sensible que el área ($p$ < α y mediana mayor). Bayes = Gaussian Naive Bayes.

## Discusión

Los resultados respaldan solo en parte la expectativa inicial. Estadísticamente, los tres métodos difieren en ambas variables, pero la magnitud importa: el área cambió como máximo 3.1 % entre medias, mientras que el perímetro cambió hasta 9.6 %, y su mayor sensibilidad se observó únicamente en los pares que incluyen a Bayes. RGB y Otsu produjeron mediciones semejantes, coherente con que sus umbrales fueran próximos (84 a 88 en las seis imágenes revisadas frente a 85).

Una explicación plausible de la mayor sensibilidad del perímetro es geométrica: un píxel aislado, una muesca o una discontinuidad en un tallo delgado añaden longitud de contorno sin modificar apreciablemente el área. Bayes decide cada píxel de forma independiente, sin contexto espacial, y la correlación entre canales viola su supuesto de independencia, aunque ello no impide clasificar bien (Domingos y Pazzani, 1997); esto podría generar bordes más irregulares y un perímetro mayor con área similar. Es una hipótesis: no se midió la irregularidad del contorno. El perímetro de 16 610 px en Bayes conviene revisarlo en la imagen original.

En la práctica, quien solo necesite el área puede elegir cualquiera de los tres métodos, dada la diferencia pequeña entre ellos frente a la variación entre imágenes (CV de 26 % a 29 %). Quien use el perímetro, o rasgos derivados de él, debe fijar y declarar el método, porque las mediciones de RGB u Otsu frente a Bayes no son intercambiables. Esto concuerda con la advertencia de que ningún criterio de color es igualmente robusto en todas las condiciones (Lu et al., 2022b).

## Limitaciones

Este análisis no emplea máscaras de referencia, por lo que se mide la discrepancia entre métodos y no su exactitud; un método puede diferir de los demás y aun así ser el más correcto. La única exactitud disponible es la de Bayes sobre 100 píxeles de prueba, con un tamaño de muestra reducido y sin intervalo de confianza calculado. El umbral de RGB se eligió visualmente y el clasificador se entrenó con solo 500 píxeles. Las 60 imágenes provienen de un solo cultivo, un entorno de interior y un fondo claro homogéneo, por lo que los resultados no deben extrapolarse al campo. Las mediciones están en píxeles y el perímetro depende de la resolución; el posprocesamiento común puede atenuar diferencias. No se calcularon tamaños de efecto ni se midió la irregularidad del contorno.

## Conclusiones

En 60 imágenes de esquejes de camote, RGB, Otsu y Bayes difirieron significativamente en el área y el perímetro, pero la diferencia fue pequeña en el área (hasta 3.1 % entre medias) y mayor en el perímetro (hasta 9.6 %). El perímetro fue más sensible que el área en los pares que incluyen a Bayes, y no en RGB–Otsu. Se recomienda fijar y declarar el método al medir el perímetro. Como trabajo futuro, se sugiere incorporar máscaras de referencia, analizar la sensibilidad al umbral y al posprocesamiento, y probar imágenes de campo.

## Disponibilidad de datos y código

Las imágenes están disponibles en Kaggle (Lu, 2022a). El código y los resultados están en el cuaderno del proyecto (Trabajo_Final_unf.ipynb) https://github.com/nforerog1/Trabajo_Final.git

## Referencias

1. Domingos, P., y Pazzani, M. (1997). On the optimality of the simple Bayesian classifier under zero-one loss. Machine Learning, 29(2–3), 103–130. https://doi.org/10.1023/A:1007413511361
2. Gehan, M. A., Fahlgren, N., Abbasi, A., Berry, J. C., Callen, S. T., Chavez, L., Doust, A. N., Feldman, M. J., Gilbert, K. B., Hodge, J. G., Hoyer, J. S., Lin, A., Liu, S., Lizárraga, C., Lorence, A., Miller, M., Platon, E., Tessman,

M., y Sax, T. (2017). PlantCV v2: Image analysis software for high-throughput plant phenotyping. PeerJ, 5, Artículo e4088. https://doi.org/10.7717/peerj.4088

3. Lu, Y. (2022a). PlantSegDatasets [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/yuzhenlu/plantsegdatasets
4. Lu, Y., Young, S., Wang, H., y Wijewardane, N. (2022b). Robust plant segmentation of color images based on image contrast optimization. Computers and Electronics in Agriculture, 193, Artículo 106711. https://doi.org/10.1016/j.compag.2022.106711
5. Otsu, N. (1979). A threshold selection method from gray-level histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62–66. https://doi.org/10.1109/TSMC.1979.4310076
6. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf
7. Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., . . . SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. Nature Methods, 17(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2