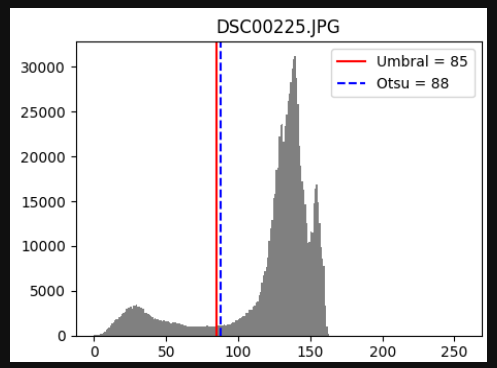
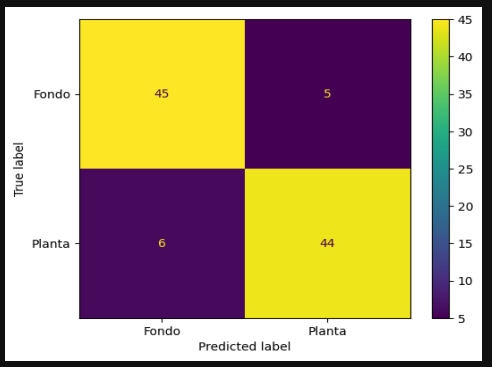
UNIVERSIDAD EAFIT

Comparación de métodos de segmentación en imágenes de esquejes de *Ipomoea batatas*









Efecto de la umbralización RGB, Otsu y Gaussian Naive Bayes en el área y el perímetro estimados.

Nixon Forero Giraldo nforerog1@eafit.edu.co · Mariana Foronda Cadavid mforondac@eafit.edu.co · Juan Esteban Arciniegas Espitia jearciniem@eafit.edu.co

UNIVERSIDAD EAFIT

La máscara condiciona la medición

IMAGEN RGB



MÁSCARA BINARIA

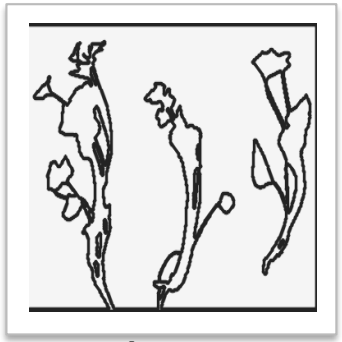


RASGOS MORFOLÓGICOS



ÁREA

Píxeles clasificados como planta



PERÍMETRO

Longitud del contorno

El fenotipado por imágenes permite medir rasgos sin destruir la planta.

Pero antes de medir, hay que separar planta y fondo. Una máscara distinta puede cambiar el área y, sobre todo, la longitud del contorno.

¿Cambian el área y el perímetro según el método?

PREGUNTA DE INVESTIGACIÓN

¿Cambian las mediciones de área y perímetro al utilizar distintos métodos de segmentación?

I Comparar

Tres métodos bajo el mismo pre y posprocesamiento.

II Contrastar

Si el área y perímetro difieren estadísticamente.

III Evaluar

Si la diferencia relativa es mayor en el perímetro.

HIPÓTESIS DE TRABAJO **El perímetro podría cambiar más que el área porque acumula las irregularidades del contorno.**

Imágenes de esquejes de camote (*Ipomoea batatas)*



60

IMÁGENES

PlantSegDatasets

2022

PUBLICACIÓN

Conjunto disponible en Kaggle

Condiciones de captura

Interior - fondo claro y homogéneo

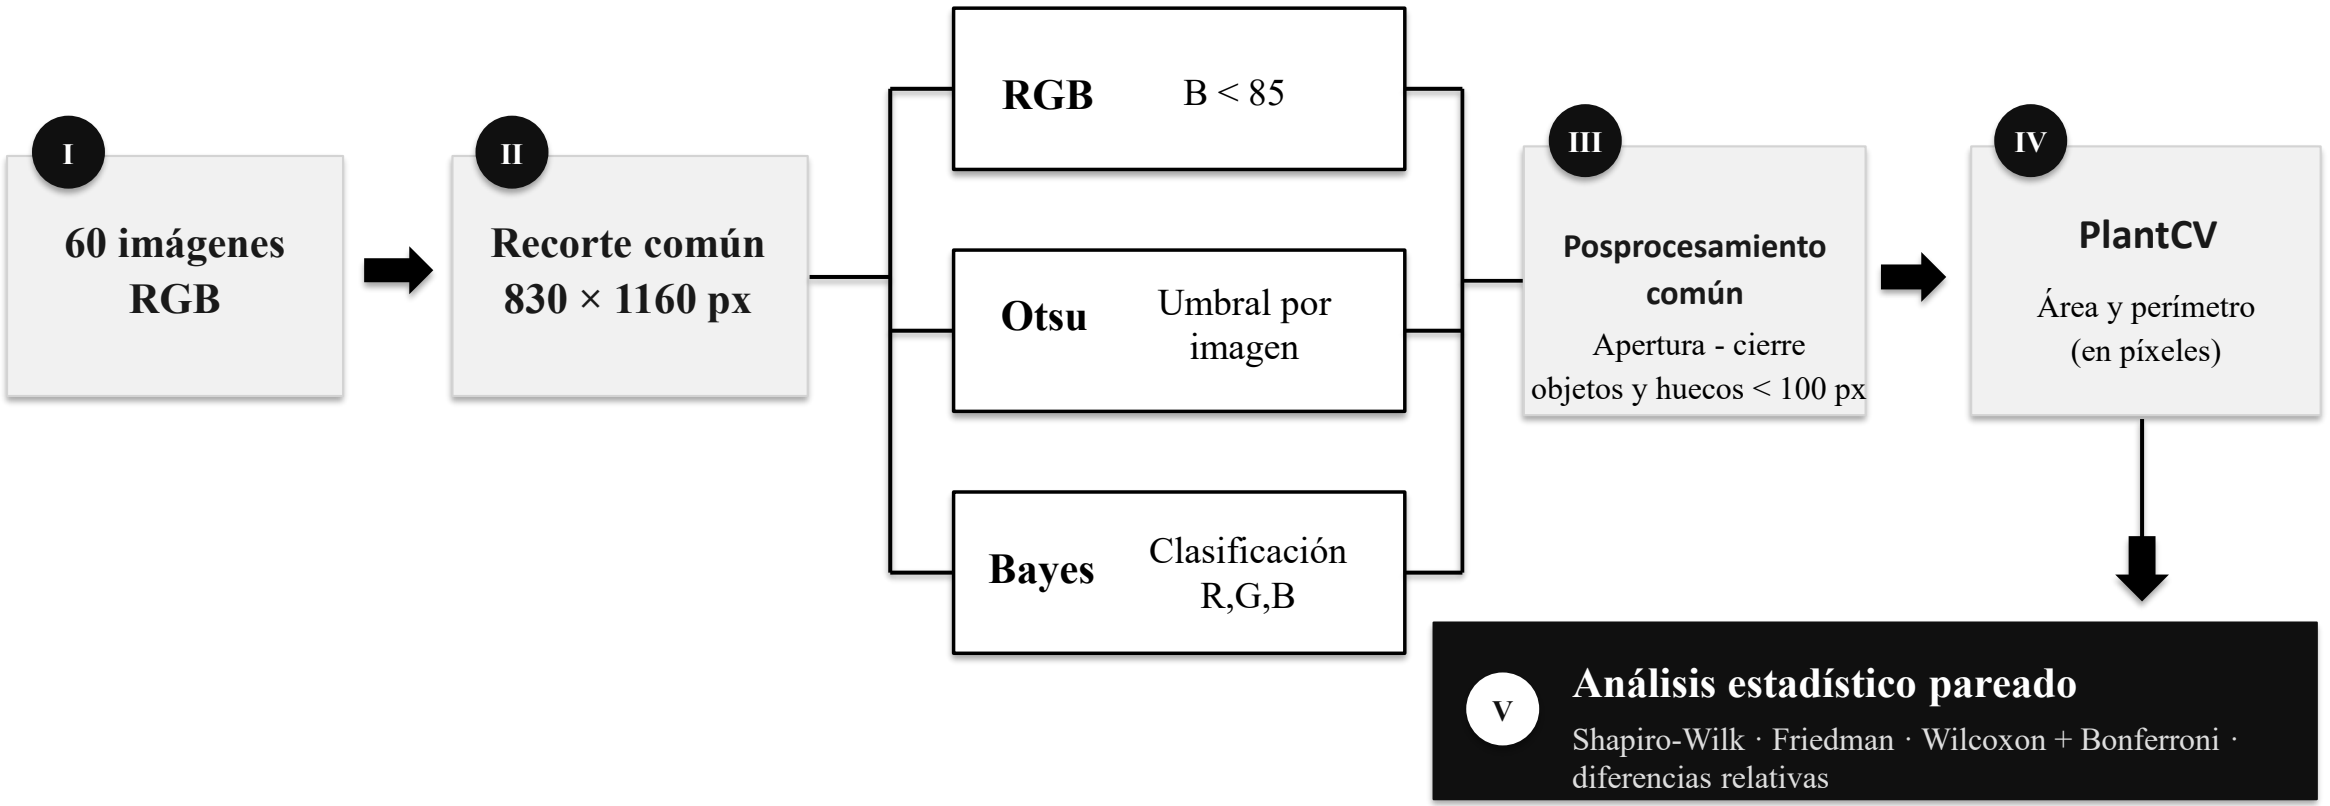
Tamaño de imagen

Original: 1224 × 918 px
Recorte común: 830 × 1160 px

Se seleccionó este subconjunto para comparar los métodos en un escenario controlado.

UNIVERSIDAD EAFIT

Diseño pareado: 1 Dataset - tres métodos



Control experimental: Recorte y posprocesamiento estandarizado.

UNIVERSIDAD EAFIT

Tres estrategias para decidir qué píxel pertenece a la planta

I RGB

Umbral fijo

B < 85

El analista fija el valor a partir del valle del histograma.

II Otsu

Umbral automático

B < t*

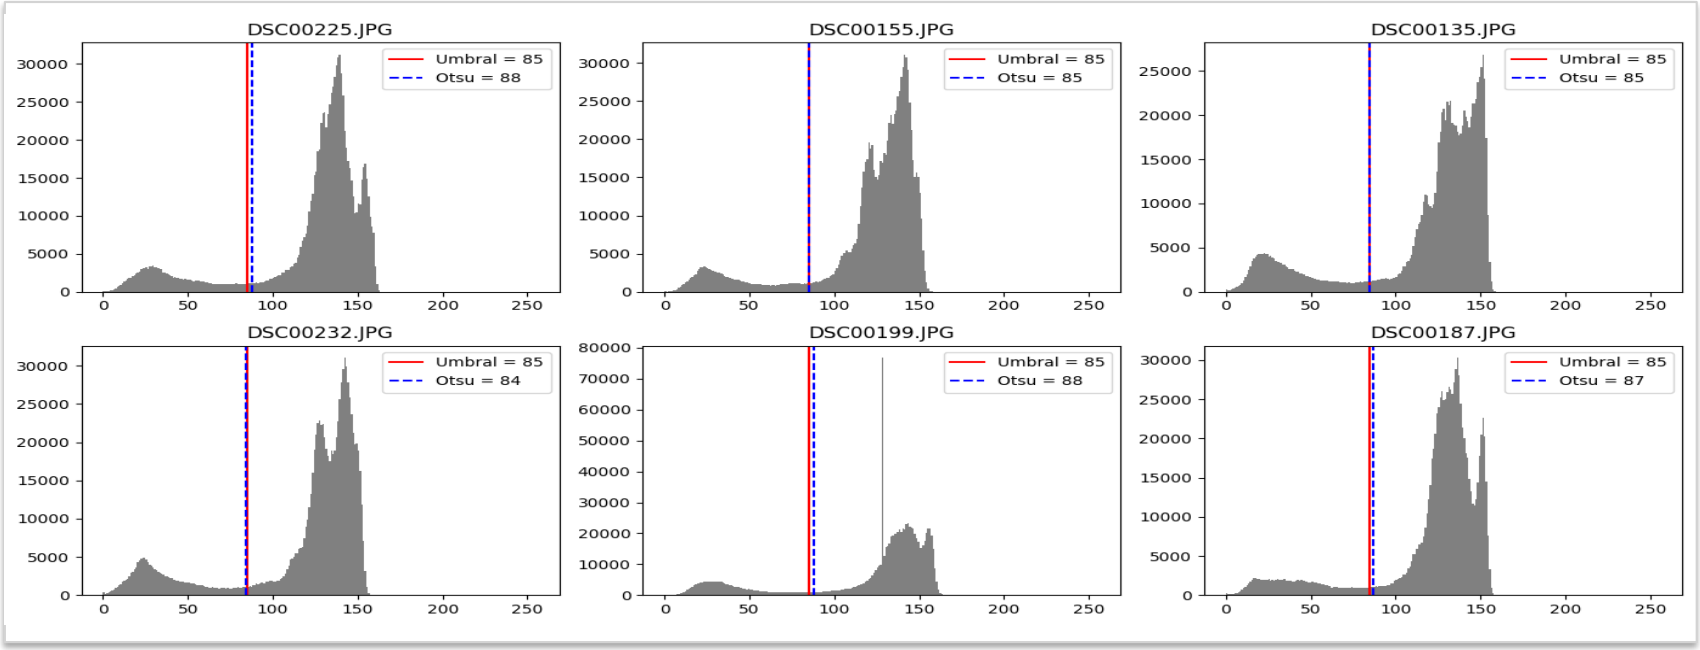
Calcula un umbral distinto para cada imagen.

III Gaussian Naive Bayes

Clasificador supervisado

R, G, B

Aprende de píxeles etiquetados y clasifica cada píxel.



¿Por qué la banda azul?

- La planta es más oscura que el fondo.
- El histograma muestra dos grupos de píxeles.
- El umbral RGB = 85 se eligió visualmente en el valle.
- En seis imágenes revisadas, Otsu dio valores entre 84 y 88.

UNIVERSIDAD EAFIT

Gaussian Naive Bayes aprende de píxeles etiquetados

ENTRENAMIENTO DEL CLASIFICADOR

500 píxeles etiquetados

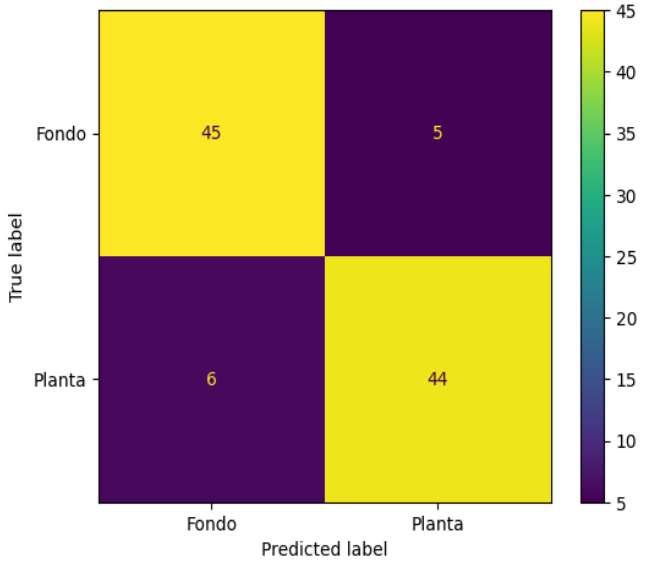
250 Fondo · 250 Planta

80 % entrenamiento
20 % prueba

GaussianNB

Cada píxel se describe con R, G y B.

RESULTADO EN LOS 100 PÍXELES DE PRUEBA



89 %

EXACTITUD

89 de 100 píxeles

Precisión:
0,882 para Fondo
y 0,898 para Planta

No es la exactitud de las máscaras completas.

UNIVERSIDAD EAFIT

La misma imagen, tres máscaras

ORIGINAL



DSC00135.JPG

RGB



B < 85

OTSU



umbral +/- 84 - 88

BAYES



Clasificación por píxel

En DSC00135, Otsu calculó 85, por ello, RGB (B < 85) y Otsu producen máscaras muy similares. Bayes también presenta una salida visual semejante en este ejemplo.

UNIVERSIDAD EAFIT

De la máscara a la comparación estadística

I · Posprocesamiento

Apertura y cierre (disco r = 1).
Eliminar objetos y rellenar huecos menores de 100 px.

II · PlantCV

Área: número de píxeles de la máscara.
Perímetro: longitud del contorno.

III · Diseño pareado

Cada imagen se procesa con los tres métodos.
Las comparaciones se hacen imagen por imagen.

SECUENCIA ESTADÍSTICA

Shapiro–Wilk
Distribución

➡

Friedman
¿Difieren los 3?

➡

Wilcoxon
¿Qué pares?

➡

Bonferroni
$\alpha = 0{,}0167$

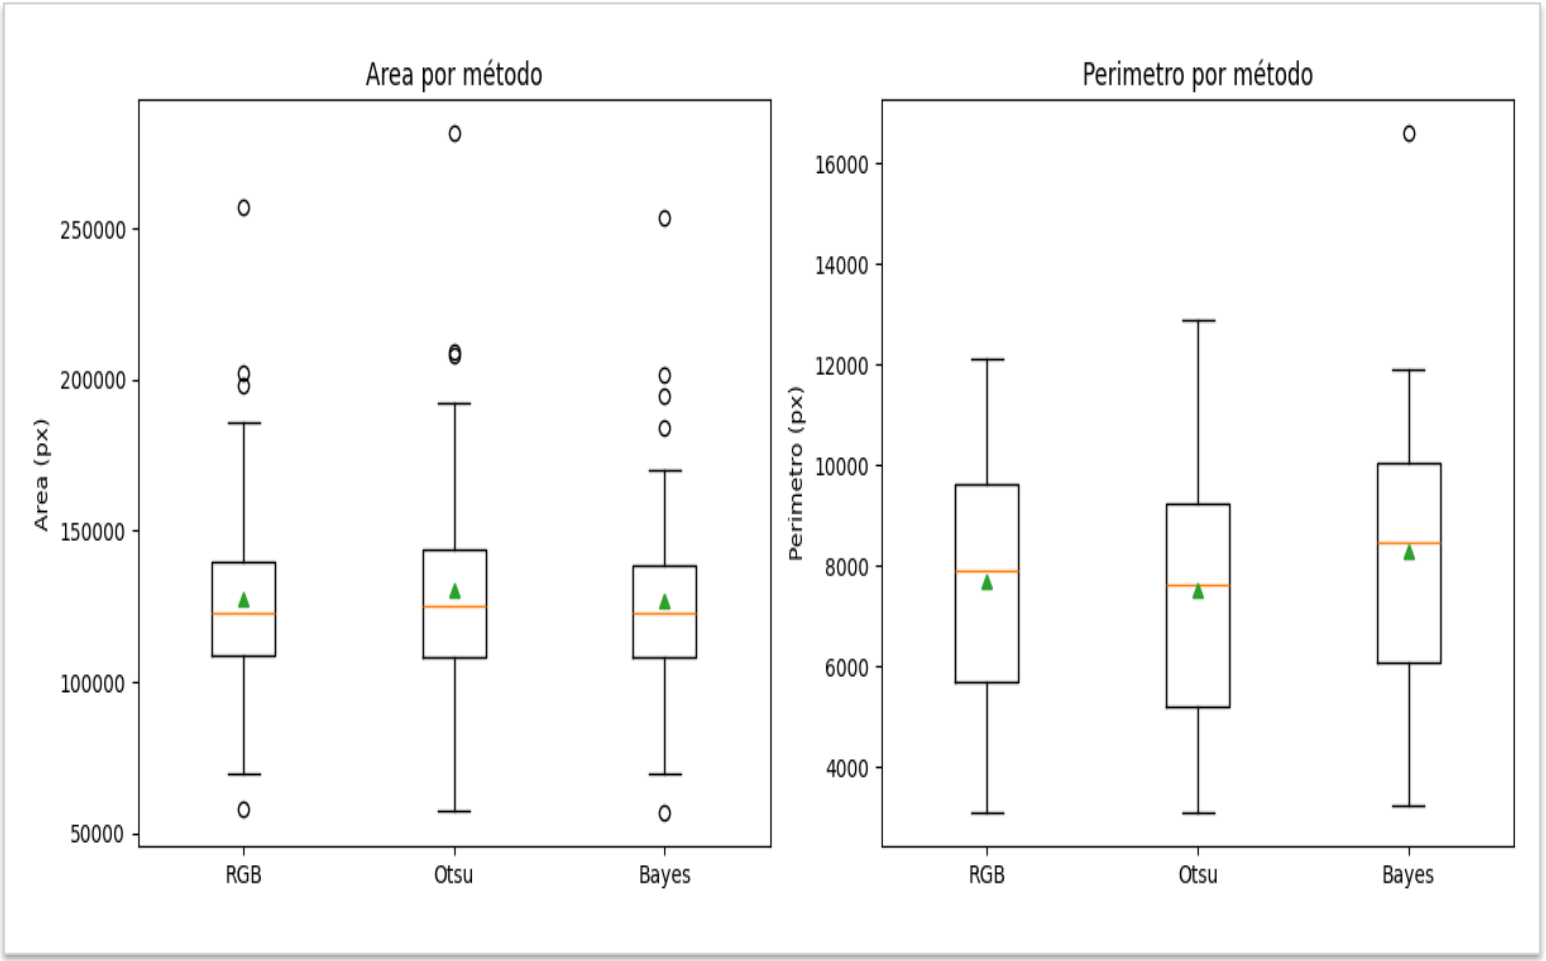
➡

Wilcoxon relativo
Área vs. perímetro

El área no fue normal ($p \leq 0{,}006$). El perímetro no rechazó normalidad ($p \geq 0{,}111$), pero tuvo un atípico extremo en Bayes. Se usaron las mismas pruebas no paramétricas para mantener comparabilidad.

UNIVERSIDAD EAFIT

Las medias variaron más en perímetro que en área



3,1 %
ÁREA
Rango relativo entre medias

9,6 %
PERÍMETRO
Rango relativo entre medias

Medias de área

126 654 – 130 614 px

Medias de perímetro

7 539 – 8 298 px

La variación entre imágenes fue mayor (CV ≈ 26–31 %); la significancia debe interpretarse junto con la magnitud.

UNIVERSIDAD EAFIT

Los tres métodos difieren en área y perímetro

32,69

FRIEDMAN · ÁREA

$\chi^2(2) \cdot p < 0{,}001$

54,86

FRIEDMAN · PERÍMETRO

$\chi^2(2) \cdot p < 0{,}001$

Bonferroni

3 comparaciones por variable

$\alpha = 0{,}05 / 3 = 0{,}0167$

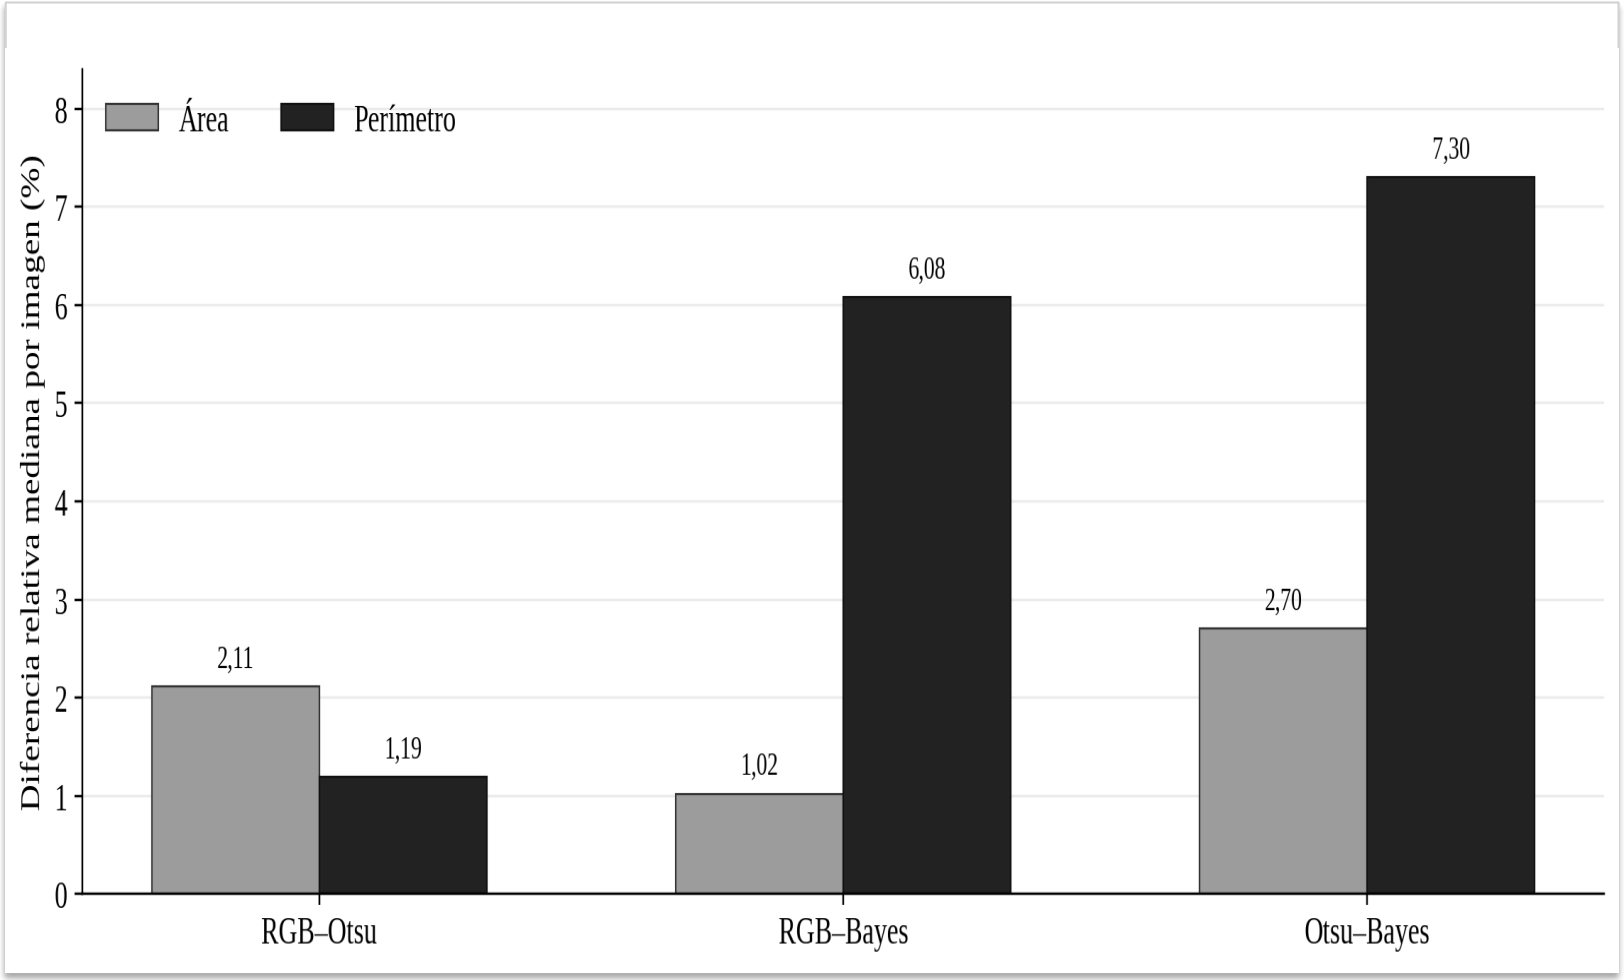
COMPARACIONES POR PARES · WILCOXON

Variable	Par	p	Decisión
Área	RGB – Otsu	< 0,001	**Difieren**
Área	RGB – Bayes	0,0008	**Difieren**
Área	Otsu – Bayes	< 0,001	**Difieren**
Perímetro	RGB – Otsu	0,0116	**Difieren**
Perímetro	RGB – Bayes	< 0,001	**Difieren**
Perímetro	Otsu – Bayes	< 0,001	**Difieren**

Con 60 pares, una diferencia pequeña también puede ser significativa: Significancia estadística ≠ relevancia práctica.

UNIVERSIDAD EAFIT

El perímetro difiere más, pero solo frente a Bayes



RGB – Otsu

2,11 % área · 1,19 % perímetro
p = 0,560

RGB – Bayes

1,02 % área · 6,08 % perímetro
p < 0,001

Otsu – Bayes

2,70 % área · 7,30 % perímetro
p < 0,001

La explicación geométrica (muescas y píxeles aislados que aumentan el contorno) es plausible, pero no se midió directamente.

UNIVERSIDAD EAFIT

¿Por qué importa estandarizar la segmentación?



Fenotipado vegetal

Área y perímetro alimentan descriptores morfológicos que pueden utilizarse para caracterizar plantas.

Reproducibilidad

Otro equipo puede obtener cifras distintas si aplica un procedimiento diferente.

Estandarización

Fijar y reportar el método permite comparar mediciones entre análisis y estudios.

RECOMENDACIÓN PRÁCTICA

Área: las medias fueron próximas entre métodos.
Perímetro y rasgos derivados: fijar y declarar el método de segmentación.

El estudio no identifica el método más exacto, evidencia que la decisión metodológica debe documentarse.

UNIVERSIDAD EAFIT

Limitaciones y próximos pasos

LIMITACIONES

I Sin máscaras de referencia: se mide discrepancia, no exactitud.

II 60 imágenes de un solo cultivo, en interiores y con fondo homogéneo.

III Umbral RGB seleccionado visualmente; Bayes entrenado con 500 píxeles.

IV Mediciones en píxeles, sin escala física.

TRABAJO FUTURO

I Incorporar máscaras de referencia para evaluar IoU y Dice.

II Evaluar más imágenes y condiciones reales de campo.

III Analizar sensibilidad al umbral y al posprocesamiento.

IV Definir escala física y estudiar rasgos derivados del perímetro.

UNIVERSIDAD EAFIT

CONCLUSIONES

La segmentación no es un paso neutro.

En 60 imágenes, los tres métodos difirieron en área y perímetro. Las diferencias entre medias fueron menores en área (3,1 %) y mayores en perímetro (9,6 %), especialmente en las comparaciones que incluyen Bayes.

Fijar y declarar el método es parte de una medición reproducible.

UNIVERSIDAD EAFIT

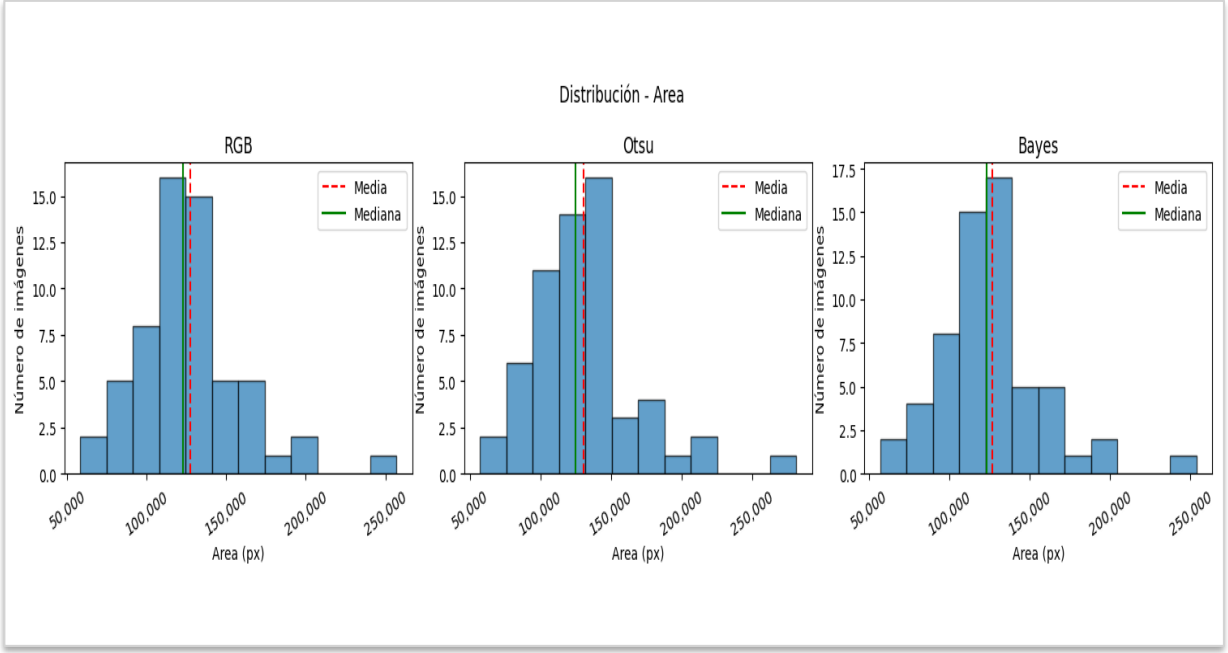
Tabla descriptiva completa

Variable	Método	Media	Mediana	DE	Mín.	Q1	Q3	Máx.	CV %	Atíp.
Área	RGB	127 524	122 704	33 784	57 992	109 080	139 982	256 924	26,5	4
Área	Otsu	130 614	125 186	37 262	57 353	108 059	143 848	281 546	28,5	3
Área	Bayes	126 654	122 856	33 246	56 832	108 203	138 400	253 763	26,2	5
Perímetro	RGB	7 711	7 907	2 373	3 104	5 690	9 648	12 139	30,8	0
Perímetro	Otsu	7 539	7 644	2 321	3 109	5 227	9 234	12 878	30,8	0
Perímetro	Bayes	8 298	8 461	2 503	3 260	6 092	10 065	16 610	30,2	1

n = 60 imágenes. DE = desviación estándar. CV = DE / media × 100. Atípicos según 1,5 × rango intercuartílico.

Distribución del área y del perímetro

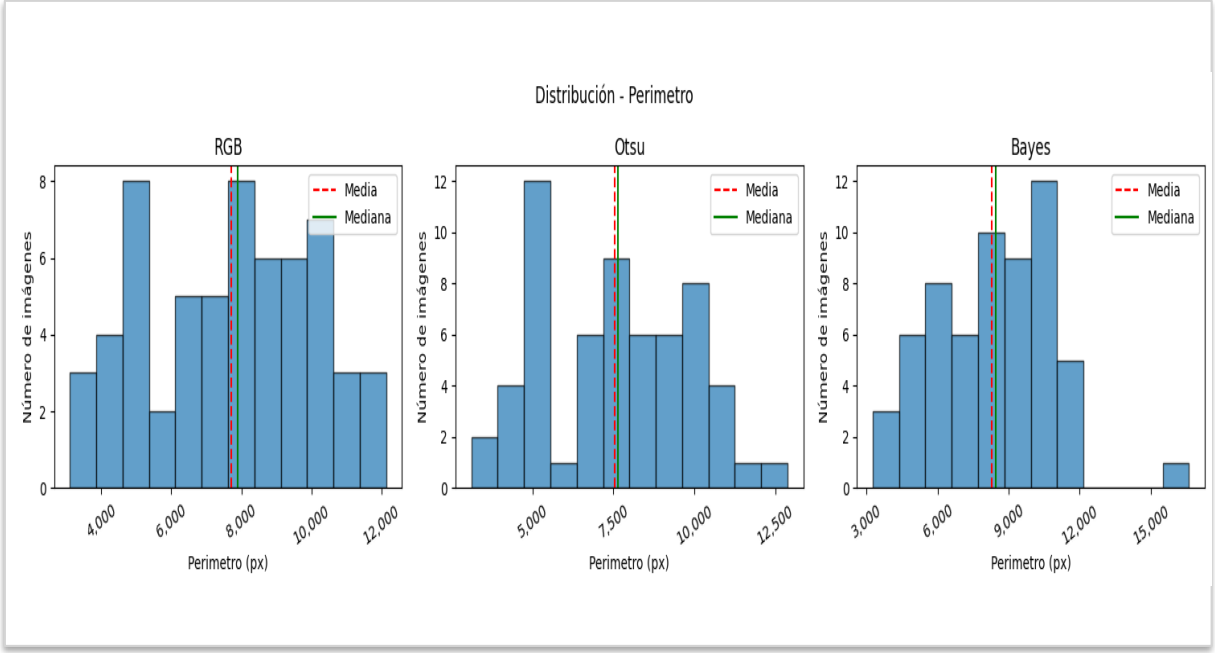
ÁREA



Shapiro–Wilk

Área: p = 0,006; 0,001; 0,005 (no normal en los tres métodos).

PERÍMETRO



Shapiro–Wilk

Perímetro: p = 0,122; 0,205; 0,111 (no se rechazó normalidad).

UNIVERSIDAD EAFIT

Resultados detallados de las pruebas

Friedman · Área $\chi^2(2) = 32{,}69 \cdot p < 0{,}001$

Friedman · Perímetro $\chi^2(2) = 54{,}86 \cdot p < 0{,}001$

Variable	Par	Dif. medias (%)	p	Decisión
Área	RGB–Otsu	2,39	<0,001	Difieren
Área	RGB–Bayes	0,68	0,0008	Difieren
Área	Otsu–Bayes	3,08	<0,001	Difieren
Perímetro	RGB–Otsu	2,26	0,0116	Difieren
Perímetro	RGB–Bayes	7,34	<0,001	Difieren
Perímetro	Otsu–Bayes	9,59	<0,001	Difieren

Sensibilidad (mediana de diferencia relativa por imagen): RGB–Otsu 2,11 % vs. 1,19 % ($p = 0{,}560$); RGB–Bayes 1,02 % vs. 6,08 % ($p < 0{,}001$); Otsu–Bayes 2,70 % vs. 7,30 % ($p < 0{,}001$).

Referencias

1. Domingos, P., y Pazzani, M. (1997). On the optimality of the simple Bayesian classifier under zero-one loss. *Machine Learning, 29*(2–3), 103–130. https://doi.org/10.1023/A:1007413511361

2. Gehan, M. A., Fahlgren, N., Abbasi, A., Berry, J. C., Callen, S. T., Chavez, L., Doust, A. N., Feldman, M. J., Gilbert, K. B., Hodge, J. G., Hoyer, J. S., Lin, A., Liu, S., Lizárraga, C., Lorence, A., Miller, M., Platon, E., Tessman, M., y Sax, T. (2017). PlantCV v2: Image analysis software for high-throughput plant phenotyping. *PeerJ, 5*, Artículo e4088. https://doi.org/10.7717/peerj.4088

3. Lu, Y. (2022a). *PlantSegDatasets* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/yuzhenlu/plantsegdatasets

4. Lu, Y., Young, S., Wang, H., y Wijewardane, N. (2022b). Robust plant segmentation of color images based on image contrast optimization. *Computers and Electronics in Agriculture, 193*, Artículo 106711. https://doi.org/10.1016/j.compag.2022.106711

5. Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics, 9*(1), 62–66. https://doi.org/10.1109/TSMC.1979.4310076

6. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf

7. Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., . . . SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Muchas gracias